

ESS 배터리 수명 조기 예측

처음 100번의 충방전 기록만으로 배터리 수명을 맞힐 수 있는가 — EDA와 모델 설계 전략

데이터 : MIT-Stanford Battery Dataset (Severson et al., *Nature Energy*, 2019) · 작성 : SKALA 4기 울산 1반 U009 김해린 · 2026.10.01

요약

항목	결론	이유
문제 유형	회귀로 푼다. 즉 "수명이 몇 사이클인지" 숫자를 예측한다.	분류(장수명/단수명)로 하면 학습 데이터에 단수명 배터리가 1개뿐이라 학습할 수 없다. (3.1)
데이터 정리	정답(수명)을 믿을 수 없는 배터리 20개를 뺀다. 학습 36개, 테스트 39개, 추가 검증 44개가 남는다.	20개 중 10개는 수명 값이 없고, 10개는 수명이 끝나기 전에 실험이 멈췄다. (2장)
핵심 단서	ΔQ 분산(10번째와 100번째 방전 곡선의 차이가 얼마나 들쭉날쭉한지)이 수명과 가장 강하게 관련된다. 상관계수 -0.90 .	원논문의 핵심 단서를 우리 데이터로 직접 검증했다. 만든 단서 16개 중, 학습 배치와 다른 배치 모두에서 관계가 유지되는 것은 이것뿐이다. (3.3, 3.5)
모델	수명에 log를 씌워 예측하고, 규제 선형 회귀(Ridge·Lasso)를 주력으로 쓴다. 트리 모델은 비교용으로만 쓴다.	테스트 배터리 수명이 학습 데이터보다 짧거나 긴 경우가 많다. 선형 모델은 이런 값도 예측할 수 있지만 트리 모델은 못 한다. 단, Batch 2는 같은 단서 값에서 수명이 더 짧아, 길게 예측할 위험이 있다. (3.3, 5장)

1. 분석 개요

1.1 왜 이 분석을 하는가 (분석방법론 1단계 · 비즈니스 이해)

ESS(에너지 저장 장치)는 전기를 저장해 두었다가 필요할 때 공급하는 설비다. 배터리는 충전과 방전을 반복할수록 늙어서, 담을 수 있는 전기의 양(용량)이 줄어든다. 용량이 처음의 80%까지 줄면 수명이 끝났다고 보고 교체한다. 이 시점을 EOL(End of Life, 수명 종료)이라고 한다.

배터리 교체 비용은 ESS 설치비의 30~40%를 차지한다. 수명을 모르면 갑자기 설비가 멈추거나, 아직 쓸 수 있는 배터리를 너무 일찍 바꾸게 된다.

분석 목적 : 처음 100번의 충방전 기록만 보고 배터리가 총 몇 번까지 버틸지(수명) 예측한다. 이렇게 하면 수명이 끝날 때까지 수백~수천 번을 기다리지 않고도 교체 시점과 예산을 미리 계획할 수 있다.

1.2 데이터

같은 연구팀이 날짜를 달리해 3번 실험했고, 한 번의 실험 묶음을 배치라고 부른다. 과제 규칙에 따라 Batch 1로 학습하고 Batch 2로 테스트한다.

실험 날짜	배치	역할	배터리 수	사이클 기록
2017-05-12	Batch 1	학습	46	38,811줄
2018-02-20	Batch 2	테스트 (필수)	47	26,904줄
2018-04-12	Batch 3	추가 검증 (선택)	46	51,007줄

배터리마다 수명, 충전 방식, 사이클별 기록(방전 용량, 내부 저항, 온도, 충전 시간), 사이클 안의 방전 곡선(Qdlin)이 들어 있다.

1.3 문제 정의 (분석방법론 2단계 · 가설 수립)

항목	내용
예측할 값 (Y)	cycle_life : 용량이 0.88Ah(처음 용량 1.1Ah의 80%)까지 떨어질 때까지 버틴 총방전 횟수
예측에 쓰는 값 (X)	2~100번째 사이클 기록으로 만든 요약값. 101번째 이후 기록은 예측 시점에 아직 없는 정보이므로 쓰지 않는다. (1번째 사이클은 기록이 전부 0이라 뺀다.)
데이터 한 줄의 단위	배터리 1개. 원래 기록은 "배터리 × 사이클" 단위라서, 배터리마다 한 줄로 요약한다.
값의 종류	충전 방식("5.4C(80%)~5.4C")은 글자로 된 이름이라 그대로 계산할 수 없어 숫자로 바꾼다. 온도(°C)는 0도가 "온도 없음"이 아니므로 평균·차이만 쓰고 "몇 배"로 해석하지 않는다.
평가 지표	MAPE(실제 수명 대비 평균 몇 % 틀렸는지). 원논문 목표는 9.1%.

2. 데이터 정리 (분석방법론 3단계 · 데이터 준비)

2.1 수명 값이 없는 배터리 10개를 뺐다

- Batch 2의 8개 : 일반 실험과 다른 특수 충전 실험(VarCharge, SLOWCYCLE)이었고, 수명 값이 기록되어 있지 않다.
- Batch 3의 2개 : 2,189번, 2,237번까지 실험했지만 그때까지도 수명이 끝나지 않았다. 그래서 수명 값이 없다.

2.2 수명이 끝나기 전에 실험이 멈춘 배터리 10개를 뺐다

Batch 1에서 가장 오래 간 배터리(수명 1,227)의 그래프를 그려 보니, 마지막 기록의 용량이 1.02Ah였다. 수명 끝 기준인 0.88Ah에 한참 못 미친다. 즉 이 배터리의 "수명 1,227"은 실제 수명이 아니라 실험을 멈춘 시점이다. 실제로는 이보다 훨씬 더 오래 간다.

0.88Ah를 기준으로 쓴 근거 : 과제 자료는 수명을 "용량이 80%가 될 때까지의 사이클 수"로 정의하고, 강사 제공 노트북은 처음 용량을 약 1.1Ah로 본다($1.1 \times 80\% = 0.88$). 실제 데이터에서도 정상 배터리 119개 모두, 기록된 수명 시점의 용량이 0.876~0.884Ah였다. 즉 이 데이터의 수명 값은 "용량이 0.88Ah에 닿은 사이클"로 계산되어 있다.

그래서 모든 배터리에 대해 "마지막 기록의 용량"을 확인했다. 수명 시점에 0.88Ah에 닿지 않았다면, 적힌 수명은 실제 수명이 아니다.




그림 1. 배터리별 마지막 기록의 용량. 점 하나가 배터리 하나다. Batch 1의 10개만 기준선(0.88Ah) 오른쪽에 떨어져 있다.

구분	마지막 기록의 용량	해당 배터리
정상 (Batch 1~3)	0.881 ~ 0.886 Ah	Batch 1 36개, Batch 3 44개
수명 끝 전에 멈춤 (Batch 1)	0.915 ~ 1.044 Ah	10개 (번호 0, 1, 2, 3, 4, 8, 10, 12, 13, 22)
Batch 2	0.826 ~ 0.838 Ah	수명 끝 이후까지 기록함 → 정상

정상 배터리와 이 10개 사이(0.886~0.915Ah)에는 배터리가 하나도 없다. 그래서 기준선을 0.89, 0.90, 0.91 중 어디로 잡아도 똑같이 이 10개만 걸러진다.

빠진 10개 중 5개는 가장 천천히 충전한 오래 가는 배터리였다. 그래서 정리 후 Batch 1의 수명 범위는 534~1,227에서 534~1,074로 좁아졌다.

2.3 잘못 측정된 기록을 뺐다

1번째 사이클(값이 전부 0)과, 순간적으로 튀어서 말이 안 되는 용량 값(0.7Ah 미만 또는 1.2Ah 초과)은 요약값을 계산하기 전에 뺐다. 전체 기록의 약 0.1%다.

결과 · 학습 Batch 1은 46개 → 36개, 테스트 Batch 2는 47개 → 39개, 추가 검증 Batch 3는 46개 → 44개 (전체 139개 → 119개)

3. 탐색적 데이터 분석 (EDA)

3.1 Q1. 수명 분포는 어떻게 생겼는가?

목적 : 맞혀야 할 정답(수명)이 어떤 값들로 이루어져 있는지, 배치마다 다른지 확인한다. 그리고 회귀와 분류 중 무엇이 가능한지 판단한다.




그림 2. 배치별 수명 히스토그램 (빨간 점선 = 분류 기준 550)




그림 3. 배치별 상자그림 (가운데 선 = 중앙값, 빨간 점 = 평균)

배치	배터리	평균	중앙값	표준편차	최소	최대	왜도	1,000 초과	500 미만	550 미만
Batch 1 (학습)	36	788	773	149	534	1,074	0.30	13.9%	0%	1개
Batch 2 (테스트)	39	566	472	222	392	1,186	1.64	7.7%	71.8%	30개
Batch 3 (추가)	44	1,060	1,006	314	541	1,935	1.26	52.3%	0%	1개

왜도 : 분포가 한쪽으로 얼마나 치우쳤는지 나타내는 값. 0이면 좌우 대칭이고, 클수록 긴 쪽으로 꼬리가 길다.

해석

- 배치마다 평균 수명이 크게 다르다. Batch 1은 788, Batch 2는 566, Batch 3는 1,060이다.
- Batch 2는 짧은 쪽에 몰려 있다. 평균(566)이 중앙값(472)보다 94 크다. 배터리 대부분(71.8%)이 500 미만인데, 소수의 오래 가는 배터리가 평균을 끌어올렸기 때문이다. 학습 데이터(Batch 1)는 거의 좌우 대칭이라(왜도 0.30), 학습과 테스트의 분포 모양이 다르다.
- 수명에 log를 씌우면 치우침이 줄어든다. 왜도가 Batch 2는 1.64에서 1.36으로, Batch 3는 1.26에서 0.52로 낮아진다.
- 테스트 배터리의 수명이 학습 데이터의 범위(534~1,074)를 벗어난다. Batch 2에는 392처럼 더 짧은 배터리가, Batch 3에는 1,935처럼 더 긴 배터리가 많다.
- 분류(550 기준 장수명/단수명)는 할 수 없다. 단수명 배터리가 학습 데이터에는 1개, 테스트 데이터에는 30개다. 모델이 배울 단수명 예시가 사실상 없다. 아무것도 배우지 않고 전부 "장수명"이라고 답해도 학습 데이터 정확도는 97.2%(35/36)가 나와 원논문(95.1%)보다 높아 보이지만, 테스트에서는 23.1%(9/39)밖에 맞히지 못한다.
- 가장 짧은 배터리들은 측정 오류가 아니다. 534, 559번은 $5.4C(80\%) - 5.4C$, 599, 616번은 $8C(35\%) - 3.6C$, 617번은 $7C(40\%) - 3.6C$ 로 모두 아주 빠르게 충전한 배터리다. 실제로 일어난 현상이므로 빼지 않는다. (Q4에서 확인)

모델에 반영 · 회귀로 수명 숫자를 예측한다. · 치우침을 줄이기 위해 수명에 log를 씌워 학습한다. · 학습 범위 밖의 수명도 예측할 수 있는 모델이 필요하다.

3.2 Q2. 열화 곡선 — 방전 용량은 어떻게 줄어드는가?




그림 4. 배치별 사이클에 따른 방전 용량 (색 = 수명, 빨간 점선 = 100번째 사이클, 회색 점선 = 수명 끝 0.88Ah)

Knee(꺾이는 지점) 찾는 방법 : Knee는 용량이 천천히 줄다가 갑자기 빨리 줄기 시작하는 지점이다. 배터리마다 곡선의 시작 점과 끝점을 직선으로 잇고, 곡선이 그 직선에서 가장 멀리 떨어진 사이클을 Knee로 정했다. 측정이 튀는 영향을 줄이려고 15사이클씩 묶어 중앙값으로 곡선을 부드럽게 만든 뒤 계산했다.

배치	배터리	Knee 위치 (중앙값)	수명 대비 Knee 위치	100번째 전에 꺾인 배터리
Batch 1	36	550번째	71%	0개
Batch 2	39	328번째	69%	0개
Batch 3	44	765번째	76%	0개

- 용량은 일정한 속도로 줄지 않는다. 모든 배터리가 처음에는 천천히 줄다가, Knee 이후 갑자기 빠르게 떨어진다.
- Knee는 수명의 약 70% 지점에서 나타나고, 100번째 사이클 전에 꺾인 배터리는 하나도 없다. Knee 위치는 수명과 거의 같이 움직이지만(상관계수 0.994), 100번째 이후에야 보이는 정보라 예측에 쓸 수 없다.
- 100번째 사이클까지는 오래 가는 배터리와 금방 죽는 배터리의 곡선이 거의 겹친다.
- Batch 2는 처음 용량이 1.10~1.12Ah로 다른 배치보다 높고, 초반에 튀는 값이 많다. 배치마다 출발점이 다르다. 이 튀는 값이 10번째~100번째 사이클 곡선에도 섞이면 ΔQ 계산이 흔들릴 수 있어, 이 영향은 이번 분석에서 따로 확인하지 못한 한계로 남긴다.

모델에 반영 · 처음 100번의 용량 값만으로는 수명을 구분할 수 없다. · 처음 100번의 감소 추세를 직선으로 늘려 수명을 계산하면, 나중에 급격히 꺾이는 것을 반영하지 못해 수명을 실제보다 길게 예측하게 된다. · 용량의 "값"이 아니라 방전 곡선의 "모양"이 어떻게 바뀌었는지 보는 단서(ΔQ)가 필요하다. · 배치마다 출발점이 다르므로 값 자체보다 "변화량"으로 만든 단서를 쓴다.

3.3 Q3. $\Delta Q(V)$ 곡선 — 처음 100번 안에서 차이가 보이는가?

$\Delta Q(V)$ 란 : 방전하면 배터리 전압이 3.5V에서 2.0V로 내려간다. Qdlin은 "전압이 각 지점까지 내려오는 동안 꺼낸 전기량"을 1,000개 지점에 기록한 곡선이다. $\Delta Q(V) = 100\text{번째 사이클 곡선} - 10\text{번째 사이클 곡선}$ 으로, 같은 전압 지점끼리 뺀 값 1,000개다.

곡선 끝(2.0V)의 차이는 매우 작다. 예를 들어 Batch 1의 한 배터리는 $1.0596 - 1.0635 = -0.004\text{Ah}$ 다. 그래서 끝 값만 보면 Q2처럼 차이가 안 보인다. 하지만 1,000개 지점 전체의 모양을 보면 차이가 드러난다. 이 모양을 분산(얼마나 들쭉날쭉한지), 최솟값, 평균으로 요약해 단서로 만들었다.

출처 : ΔQ 분산은 원논문(Severson et al., 2019)이 수명 예측의 핵심 단서로 제시한 값이다. 이 보고서에서는 이 단서가 우리가 정리한 데이터에서도, 특히 학습에 쓰지 않은 Batch 2·3에서도 통하는지 직접 확인했다.




그림 5. 배치별 $\Delta Q(V)$ 곡선 (색 = 수명, 어두울수록 수명이 짧음)




그림 6. ΔQ 분산(log)과 수명(log 축). 점선은 세 배치 전체에 맞춘 직선

ΔQ 요약값	Batch 1	Batch 2	Batch 3	전체
분산 (log)	-0.83	-0.90	-0.70	-0.86
분산	-0.80	-0.73	-0.59	-0.74
최솟값	0.81	0.82	0.69	0.82
평균	0.77	0.77	0.64	0.79

표의 값은 수명과 상관계수다. 수명에도 log를 씌우면 분산(log)과의 상관관계는 전체 -0.90이다.

- 수명이 짧은 배터리일수록 3.2~2.5V 구간에서 ΔQ 곡선이 깊게 파인다. Batch 2는 -0.08Ah 근처까지 파이고, 오래 가는 배터리는 -0.02Ah 수준이다. Q2에서 용량 값으로는 안 보이던 차이가, ΔQ 곡선 모양에서는 100번째 사이클에 이미 보인다.
- ΔQ 분산이 클수록 수명이 짧다(상관계수 음수). 분산에 log를 씌우면 수명과 관계가 직선 모양이 된다.
- 세 배치 모두 " ΔQ 분산이 클수록 수명이 짧다"는 방향은 같다. 수명이 긴 Batch 3는 직선의 왼쪽 위로 이어져 같은 직선을 따른다. 그래서 학습 범위보다 긴 배터리는 직선을 연장해 예측할 수 있다.
- 단서 값 자체도 배치마다 범위가 다르다. ΔQ 분산(log)의 범위는 Batch 1이 -4.18 ~ -3.35, Batch 2가 -4.45 ~ -3.09, Batch 3가 -5.10 ~ -3.45다. 테스트 배치의 단서 값 일부가 학습 범위 밖에 있으므로, 정답(수명)뿐 아니라 입력값도 학습 범위를 벗어난다. 이 점도 범위 밖으로 연장할 수 있는 선형 모델을 고르는 이유다.

- 단, Batch 2는 직선 아래쪽에 몰려 있다. 같은 ΔQ 분산에서 Batch 2 배터리의 수명이 더 짧다는 뜻이다. 배치에 따라 직선의 높이가 다를 수 있으므로, 테스트(Batch 2)에서는 수명을 실제보다 길게 예측할 위험이 있다.
- Batch 3의 일부 오래 가는 배터리는 3.1V 근처에서 곡선이 위로 솟는 다른 모양을 보인다. 과제 안내에서 "배치마다 충전 곡선 시작 시점이 달라 Qdlin을 단순 비교하면 왜곡이 생긴다"고 한 부분과 관련될 수 있어, 배치 간 차이로 주의한다. 대응 : Batch 3로 추가 검증할 때는 배터리별 오차를 따로 계산해, 곡선 모양이 다른 배터리에서 오차가 특히 큰지 확인하고 그 결과를 원인 분석에 쓴다.

모델에 반영 · ΔQ 분산(log)을 핵심 단서로 쓴다. · 수명에도 log를 씌워 직선 관계를 유지하고, 선형 모델로 학습 범위 밖까지 예측한다. · 분산·최소값·평균은 같은 곡선에서 나온 비슷한 정보라 하나만 쓴다. (Q5) · Batch 2가 직선 아래에 있는 이유는 학습 데이터(Batch 1)만으로는 확인할 수 없다. 원인 후보(배치마다 다른 초기 용량 수준, 초반 튀는 값)는 피쳐로 넣지 않고 기록만 해 두었다가, 테스트 결과(Valid-Test 차이)를 해석할 때 쓴다.

3.4 Q4. 충전 조건(C-rate)과 수명은 어떤 관계인가?

충전 방식을 숫자로 바꿨다. C-rate는 충전 속도다(1C = 1시간에 완충, 4C = 15분에 완충). 충전 방식 8C(15%)–3.6C는 "15%까지 8C로 충전하고, 그 뒤는 3.6C로 충전"이라는 뜻이다. 여기서 1단계 속도(C1=8), 전환 지점(Q1=15%), 2단계 속도(C2=3.6)를 꺼냈다.

그리고 80%까지 채우는 데 걸린 시간으로 평균 속도(Cavg_80)를 계산했다.

- 8C(15%)–3.6C : 15%를 8C로($0.15 \div 8$) + 65%를 3.6C로($0.65 \div 3.6$) = 0.199시간(약 12분) → 평균 $0.8 \div 0.199 = 4.0C$
- 5.4C(80%)–5.4C : 80%를 5.4C로($0.8 \div 5.4$) = 0.148시간(약 9분) → 평균 5.4C

1단계 속도는 8C가 더 빠르지만, 80%까지 채우는 것은 5.4C 방식이 더 빠르다.




그림 7. Batch 1 충전 방식별 평균 수명 (색 = 80%까지 평균 충전 속도, n = 배터리 수)




그림 8. 80%까지 평균 충전 속도와 수명 (배치별)

충전 단서와 수명의 상관계수	Batch 1	Batch 2	Batch 3	전체	ΔQ 분산(log)과의 상관 (전체)
C1 (1단계 속도)	-0.24	0.19	-0.08	0.01	0.01
Q1 (전환 지점)	-0.18	0.12	0.54	0.17	-0.12
C2 (2단계 속도)	-0.24	-0.12	-0.04	-0.10	0.13
Cavg_80 (80%까지 평균 속도)	-0.58	0.33	-0.02	-0.10	0.10

- **충전 방식별 평균 수명 (Batch 1)** : 가장 짧은 방식은 5.4C(80%) - 5.4C(546.5), 가장 긴 방식은 4.4C(80%) - 4.4C(1,074)다. 8C(15%) - 3.6C는 1단계가 8C로 가장 빠르데도 수명이 1,008.5로 길다. 빠른 구간이 15% 뿐이라 평균 속도는 4.0C로 느린 편이기 때문이다. 그래서 1단계 속도(-0.24)보다 **80%까지 평균 속도(-0.58)**가 수명과 더 관련된다. 단, 방식마다 배터리가 1~2개뿐이라 "경향" 정도로 본다.
- **빨리 충전한 배터리는 정말 수명이 짧은가?** Batch 1 안에서는 그렇다(-0.58). 하지만 세 배치를 합치면 -0.10으로 관계가 거의 사라진다. Batch 2와 3은 모든 방식의 평균 속도가 4.8C로 같은데도, 수명이 약 390에서 1,935까지 크게 다르다.
- **충전 방식과 초기 열화 속도** : 초기 열화 속도를 "2~100번째 사이클 동안 용량이 줄어드는 기울기"로 정하면, 평균 충전 속도와의 상관은 Batch 1에서 -0.62(빨리 충전할수록 용량이 빨리 줄어듦), 전체에서 -0.16이다. ΔQ 분산과는 상관이 0.01~0.13으로 거의 없다.
- **배치끼리 충전 방식이 거의 겹치지 않는다.** Batch 1의 20가지 방식 중 Batch 2와 같은 것은 2가지, Batch 3과 같은 것은 1가지뿐이다.
- 모두 "함께 나타난다"는 상관관계일 뿐이며, "빨리 충전해서 수명이 짧다"는 원인-결과로 단정하지 않는다.

모델에 반영 · 충전 방식을 이름 그대로 넣으면 테스트 배치의 방식 대부분이 처음 보는 이름이라 쓸 수 없다. 그래서 숫자로 바꿔 쓴다. · 숫자로 바꿔도 Batch 1에서만 통하는 관계라, 학습 배치에만 맞춰지는 위험이 있다. 그래서 보조 단서로만 시험해 본다.

3.5 Q5. 어떤 단서가 수명과 관련되어 있는가?

2~100번째 사이클로 만든 단서 16개(4장 표)와 수명(log)의 상관계수를 구했다. 어떤 단서를 쓸지는 **학습 데이터(Batch 1) 기준**으로 판단한다. 테스트 데이터를 보고 단서를 고르면 시험 문제를 미리 보는 것과 같아서(데이터 누수), 전체 배치 값은 참고만 한다.

단서	Batch 1	전체	판단
ΔQ 분산(log)	-0.84	-0.90	핵심
ΔQ 분산	-0.84	-0.83	핵심과 같은 정보
ΔQ 최솟값	0.83	0.88	
ΔQ 평균	0.80	0.85	
80%까지 평균 충전 속도	-0.59	-0.15	Batch 1에서만 관련
초기 충전 시간	0.58	0.23	
용량 감소 기울기	0.55	-0.11	
용량 감소량	0.52	0.00	
초기 용량	0.16	-0.62	배치를 합칠 때만 관련
초기 내부 저항	0.12	-0.47	
평균 / 최고 온도	-0.16 / -0.15	0.32 / -0.01	약함
C1 / Q1 / C2	-0.24 / -0.18 / -0.29	0.09 / 0.12 / -0.18	약함
내부 저항 변화량	0.14	0.22	약함

서로 너무 비슷한 단서 (다중공선성) : 두 단서의 상관이 매우 높으면 사실상 같은 정보다. 이런 단서를 함께 넣으면 모델이 같은 정보를 두 번 받아 결과가 불안정해진다. Batch 1에서 상관이 0.8 이상인 짝은 다음과 같다.




그림 9. 단서끼리, 그리고 수명(log)과의 상관계수 히트맵 (Batch 1). 빨간색은 함께 커지는 관계, 파란색은 반대로 움직이는 관계이며 색이 진할수록 관계가 강하다. 맨 아래 줄이 수명과의 상관이다.

- ΔQ 분산·분산(log)·최솟값·평균 4개끼리 : 0.96 ~ 0.99
- 용량 감소량과 용량 감소 기울기 : 0.995 / 초기 충전 시간과 80%까지 평균 충전 속도 : -0.994
- 평균 온도와 최고 온도 : 0.953 / C1과 Q1 : -0.845
- ΔQ 단서만 학습 배치와 전체 모두에서 강하다. 배치가 바뀌어도 관계가 유지되는 단서다.
- 충전 속도와 용량 감소 기울기는 Batch 1 안에서만 관련이 있고(약 0.55), 배치를 합치면 사라진다. Q4와 같은 결과다.
- 초기 용량과 초기 내부 저항은 반대로 배치를 합칠 때만 관련이 나타난다. Batch 1 안에서는 관련이 약하다. 배치마다 초기 용량 수준과 수명 수준이 함께 달라서 생긴 관계로 보인다. 이 단서를 쓰면 모델이 배터리의 상태가 아니라 "어느 배치인지"를 외울 위험이 있다.

모델에 반영 · 핵심 단서는 ΔQ 분산(log) 1개다. · 서로 비슷한 단서는 묶음마다 1개만 쓴다. · 학습 배터리가 36개뿐이므로 단서 수를 최소로 하고, 규제가 있는 모델을 쓴다.

4. 단서 만들기와 고르기 (Feature Engineering) (3단계 · 데이터 변환)

묶음	만든 단서	계산 방법 (2~100번째 사이클)	만든 이유	판단
$\Delta Q(V)$	분산(log), 분산, 최솟값, 평균	100번째 – 10번째 방전 곡선(1,000개 값)의 분산·최솟값·평균	용량 값으로 안 보이는 곡선 모양 변화 (Q2, Q3)	핵심 : 분산(log)
용량	초기 용량, 감소량, 감소 기울기	2번째 용량 / 100번째 – 2번째 / 2~100번째의 직선 기울기	초기 열화 정도 (Q2)	보조 후보 1개
내부 저항	초기 저항, 저항 변화량	2번째 저항 / 100번째 – 2번째	늘수록 저항이 커짐 (도메인)	배치 차이 주의
온도	평균 온도, 최고 온도	사이클별 평균·최고 온도의 평균	열이 많을수록 빨리 늡음 (도메인)	둘 중 1개
충전 조건	C1, Q1, C2, 평균 충전 속도, 초기 충전 시간	충전 방식 이름에서 숫자 추출 / 80%까지 걸린 시간으로 계산 / 처음 5사이클 충전 시간의 중앙값	빠른 충전의 영향 (Q4)	보조 (Batch 10에 서만 관련)

쓰지 않는 정보 : 101번째 이후 사이클(예측 시점에 아직 없음), Knee 위치(100번째 이후에야 보임), 충전 방식 이름 자체(테스트 배치 방식 대부분이 학습에 없음).

고르는 기준 ① 학습 배치와 다른 배치 모두에서 관계가 유지되는가 ② 서로 비슷한 단서는 묶음마다 1개만 ③ 학습 배터리가 36개뿐이므로 단서는 최소로.

진행 방법 : ΔQ 분산(log) 1개로 시작한다. 보조 후보(용량 감소 기울기, 평균 충전 속도, 평균 온도 등)를 한 번에 하나씩 추가해 보고, 검증 데이터의 오차(MAPE)가 줄어들 때만 남긴다. 매번 결과를 기록한다.

5. 모델 설계 전략 (분석방법론 4단계 · 분석 모델 정의)

5.1 데이터 처리

- 예측할 값** : 수명에 log를 씌운 값(log10 수명)을 예측한다. 수명 분포의 치우침이 줄고(Q1), ΔQ 분산(log)과 직선 관계가 되기 때문이다(Q3). 예측한 값은 다시 10의 거듭제곱으로 되돌려 실제 수명으로 바꾼 뒤 MAPE를 계산한다.
- 데이터 나누기** : 학습은 Batch 1, 테스트는 Batch 2다(과제 규칙). Batch 1에서 배터리 9개(약 25%)를 따로 떼어 검증용(Hold-out)으로 쓴다. 이때 무작위로만 뽑으면 비슷한 수명의 배터리만 뽑힐 수 있으므로, 수명을 몇 구간으로 나눠 구간마다 고르게 뽑는다(층화 추출). 배터리 단위로 떼는 이유는, 섞어서 나누면 같은 충전 방식의 배터리가 학습과 검증에 나뉘어 들어가 검증 점수가 실제보다 좋게 나올 수 있기 때문이다(데이터 누수). 테스트(Batch 2)는 모델을 다 만든 뒤 마지막에 한번만 평가한다. **한계와 대응** : 검증용이 9개뿐이라 배터리 1~2개의 결과에 따라 검증 점수가 크게 흔들릴 수 있다. 그래서 검증 점수 하나만 보지 않고, 학습 데이터 안의 교차검증(CV) 평균과 함께 비교해 판단한다.
- 결과 재현과 누수 방지** : 무작위 값은 random_state = 42로 고정한다. 단서마다 단위가 달라서 표준화(StandardScaler)로 단위를 맞추는데, 기준값(평균·표준편차)은 학습 데이터로만 계산하고 검증·테스트에는 그 기준을 그대로 적용만 한다.

5.2 후보 모델

역할	모델	고른 이유 (EDA 결과와 연결)
기준선	선형 회귀 (ΔQ 분산(log) 1개)	ΔQ 분산(log)과 수명(log)이 직선 관계다(Q3). 직선을 연장해 학습 범위 밖 수명도 예측할 수 있다(Q1). 다만 Batch 2는 직선보다 아래에 있어(Q3), 테스트에서 수명을 길게 예측할 위험을 함께 확인한다. 직선 관계라는 가정이 맞는지는 예측 오차의 패턴으로 확인한다.
주력	Ridge · Lasso · ElasticNet (규제 선형 회귀)	규제 모델은 단서의 영향력을 일부러 작게 눌러, 적은 데이터를 외워 버리는 것(과적합)을 막는다. 학습 배터리가 36개로 적고 비슷한 단서가 많아서(Q5) 필요하다. Lasso는 쓸모없는 단서의 영향력을 0으로 만들어 단서를 골라 주고, Ridge는 모든 단서를 조금씩 반영한다. 규제 세기(α)는 무작위 탐색(Random Search)으로 범위를 좁힌 뒤 격자 탐색(Grid Search)으로 정하며, 검증 데이터로만 판단한다.
비교용	RandomForest · GradientBoosting (트리 모델)	혹시 직선이 아닌 관계가 있는지 확인하는 용도다. 트리 모델은 학습 데이터 정답들의 평균으로 예측하기 때문에, 학습 최대 수명(1,074)보다 큰 값을 예측할 수 없다. Batch 3의 수명 1,935 배터리는 아무리 잘해도 오차가 $(1,935 - 1,074) \div 1,935 = 44.5\%$ 이상이다. 부스팅 모델은 과적합에도 주의해야 한다.
쓰지 않음	딥러닝 · 여러 모델 합치기(앙상블)	학습 배터리 36개로는 데이터가 너무 적어 과적합되기 쉽고, 결과를 설명하기 어렵다.